

1. 함수로서의 인간과 인공지능(AI)

(1) 입출력(Input/Output) 관계→함수

- 인간과 함수의 유사성: 수학에서 '함수'란 특정 입력값(Input)에 대응하여 출력값(Output)을 도출하는 체계를 의미한다. 이러한 관점에서 보면, 외부 자극을 수용하여 행동이나 판단을 출력하는 인간 역시 하나의 거대한 함수로 정의할 수 있다.
- 인공지능(AI)의 수학적 본질: 인간과 유사하다고 말하는 AI 또한 본질적으로 입출력 구조를 지닌 함수이다. AI가 처리하는 현실 세계의 데이터(이미지, 음성, 텍스트 등)는 컴퓨터가 연산할 수 있는 수학적 형태로 변환되어야 한다.

(2) 데이터의 벡터(Vector)화 및 행렬(Matrix)의 역할

- 벡터와 공간 상의 한 점: 모든 입력 데이터는 연속적인 숫자의 배열인 '한 줄의 숫자(벡터)'로 표현 가능해야 한다. 수학 및 데이터 시각화(Data Visualization) 관점에서 이 벡터는 다차원 공간 상의 '한 점(Point)'을 의미한다.
- 함수 역할을 수행하는 행렬: 입력 벡터가 출력 벡터로 변환되는 과정의 핵심은 '행렬(Matrix)'이다. 인공지능 모델의 실체는 거대한 수치들로 이루어진 행렬이며, 이 행렬 자체가 입력과 출력을 매개하는 함수의 가중치(Weight) 역할을 수행하는 것이다.
- 파라미터(Parameter) 규모의 예시: 모델의 성능과 크기는 행렬을 구성하는 파라미터의 개수로 결정된다. 예컨대 수업 중 다룬 소형 모델의 파라미터 수가 47개 수준($9 \times 6 = 54$ 등 행렬 연산 기반)이라면, 초창기 대형 언어 모델인 GPT-1(또는 초기 버전)은 무려 1,755개(혹은 그 이상)의 파라미터를 보유한 거대 행렬이었다.

2. 딥러닝 AI의 구현 과정과 학습(Training) 메커니즘

ex. '개인 맞춤형 건강 관리 예측 어플리케이션' 구축 과정

(1) 데이터 파이프라인 및 빅데이터의 자산적 가치

- 입출력 데이터 변수 설정:
 - 입력값(Input Vector) 수면 시간, 운동량, 식사량(칼로리 섭취량)
 - 출력값(Output Vector): 체중, 혈압
- 빅데이터 수집 필요성: 입력값을 행렬곱하여 정확한 체중과 혈압을 예측하기 위해서는 빈 행렬을 채워줄 '가치 있는 정답지(빅데이터)' → 스몰 데이터로는 행렬의 정확한 가중치를 찾아낼 수 없다.

- 데이터 구축의 경제적 비용: 신뢰할 만한 패턴을 도출하고 상용화 가능한 앱을 만들기 위해서는 최소 **1만 명(10,000명)** 규모의 표본 데이터가 요구된다. 수집을 위해 피실험자에게 인센티브(예: **5,000원** 상당의 스타벅스 기프티콘)를 제공한다고 가정할 때, 순수 데이터 구축 비용만 최소 **5,000만 원**이 소요된다.

- 현대 산업에서 "데이터가 곧 자본이자 핵심 자산"

(2) 오차 역전파(Backpropagation)와 가중치 수렴 과정

1) 초기화(Initialization)

최초의 AI 중간 행렬에는 아무런 가치가 없는 무작위 숫자(Random Weight)를 임의로 대입하고 시작한다.

2) 순전파(Forward Propagation) 및 오차 발생

1번 피실험자의 입력 데이터(수면, 운동, 식사)를 초기 행렬에 곱하면, 터무니없는 예측값(예: 체중 **1005kg**, 혈압 **200** 등)이 도출된다.

3) 오차(Loss) 계산:

인공지능은 자신이 출력한 예측값과 실제 데이터의 정답(실제 체중 및 혈압)을 비교하여 '두 값 사이의 차이(오차)'를 정량화한다. (예: 두 지표의 오차 합이 **130**만큼 발생함)

4) 가중치 업데이트(Weight Update):

도출된 오차(**130**)를 바탕으로, 중간 행렬 내부의 숫자들을 정답과 가까워지는 방향으로 아주 미세하게 조정(업데이트)한다.

5) 반복 학습(Iteration) 및 수렴(Convergence):

이 과정을 1만 명의 데이터에 대해 끊임없이 반복 수행하면, 어느 순간 행렬 내 가중치 숫자들이 더 이상 변하지 않고 일정 값으로 고정되는 상태에 도달한다. 공학적으로 이를 '학습이 완료(Convergence·수렴)되었다'고 정의한다.

(3) 수정 및 학습 과정

- 오답 노트를 통한 학습: 이는 인간이 시험을 치른 후 틀린 문제를 분석(오답 노트 정리)하여 머릿속의 지식 체계를 수정해 나가고, 최종적으로 성적이 특정 점수(예: **80점**)로 수렴하는 발달·학습 과정과 일치한다.
- 상용 모델의 동결(Freeze) 상태: 학습이 완료되어 가중치가 완전히 고정된 행렬 상태가 우리가 현재 사용하는 ChatGPT 등의 상용 AI 서비스이다. 이 고정된 행렬은 매일 바뀌지 않으며, 버전 패치(예: **5.5**에서 **5.6**으로 업그레이드)가 이루어질 때 비로소 행렬 내부의 숫자가 일괄적으로 업데이트되는 구조를 갖는다.

3. 인공지능 기반의 서비스 모델 파이프라인 (AICC 예시)

실제 비즈니스 환경에서 AI는 단일 모델이 아니라, 앞서 언급된 음성인식(STT)을 포함한 여러 기능형 AI들이 파이프라인(Pipeline)으로 연결되어 작동한다.

- AICC(인공지능 콜센터) 시스템 구조:
 - **STT (Speech-to-Text):** 고객의 음성 인풋을 받아서 텍스트 문장으로 변환한다.
 - **LLM (Large Language Model):** 변환된 텍스트를 입력받아, 프롬프트(지침)에 따라 고객에게 할 적절한 답변을 텍스트 아웃풋으로 생성한다.
 - **TTS (Text-to-Speech):** LLM이 출력한 텍스트 답변을 다시 자연스러운 인간의 음성으로 변환하여 고객에게 들려준다.
- AI 성능의 3대 평가 요소:
 - **정확도:** 할루시네이션(환각·거짓말) 없이 올바른 정보를 제공하고 상담 라우팅(부서 연결)을 정확히 해내는 능력.
 - **속도:** 고객이 답답함을 느끼지 않도록 실시간으로 빠르게 연산하여 답변하는 능력.
 - **비용:** 고성능 컴퓨터(GPU) 인프라 자원을 최소화하여 얼마나 저렴하고 효율적으로 처리할 수 있는가의 능력.

4. 결론

수업의 마무리에서는 현재 실리콘밸리와 미디어가 과장하고 있는 AI의 환상을 걷어내고, 공학적인 한계와 현실을 직시해야 함을 강조했다.

- 기존 권위에 대한 의심과 'Unlearn'의 필요성 : 책이나 저명한 학자, 미디어가 말하는 권위에 매몰되지 않고 모든 지식을 부정하고 의심해 보는 공학적 습관이 중요하다.
- AGI(일반인공지능) 논쟁의 진실 : 인간처럼 영혼을 갖고 모든 분야에서 다재다능하게 두각을 나타내는 AGI가 곧 도래할 것이라는 주장은 과장에 가깝다. 안르쿤(메타), 앤드류 응(코세라) 같은 양심적인 학자들은 이에 비판적이며, 엔비디아(젠슨 황)나 오픈AI(샘 올트먼)처럼 주가와 상품을 팔아야 하는 기업가들이 디스토피아/유토피아적 환상을 자극하는 경향이 있다.
- 현재 생성형 AI(LLM)가 마주한 명확한 한계:
 1. 데이터의 고갈 : LLM의 성능 향상을 이끌었던 인터넷상의 공개된 언어 빅데이터를 인류는 이미 거의 다 긁어다 썼다(크롤링 고갈). 추가할 양질의 데이터가 바닥났기 때문에 최근 모델들은 버전이 올라가도(아이폰의 연례 업데이트처럼) 성능의 극적인 변화를 체감하기 어렵다.
 2. 하드웨어와 전력 한계 : AI의 파라미터가 커질수록 GPU 데이터 센터를 돌리기 위한 전력이 기하급수적으로 소모되는데, 지구상의 기존 전력망으로는 이를 감당할 수 없다. (S.올트먼이나 일론 머스크가 원자력 발전소나 우주 발전을 운운하는 이유이다)

3. 알고리즘의 정체 : 현재 트랜스포머 기반의 **AI** 알고리즘은 본질적으로 약 80년 전 이론에 뿌리를 두고 있으며, 근본적인 구조 변혁이 없는 한 기술적 포화 상태(수렴·**Saturation**)에 이르렀다.
4. 논리 및 검색의 멍청함 (실제 사례) : 방대한 텍스트 파일(2,000줄의 콜센터 요약본)에서 단순히 초등학생도 할 수 있는 '요청'이라는 단어의 빈도수를 세는 단순 노동조합조차, 최신 고성능 AI(**Gemini, GPT** 등)들은 돌릴 때마다 결과가 다르게 나오고 계속 틀리는 수준의 치명적인 한계를 보여준다. 정답지가 확실한 수학이나 코딩 분야와 달리, 언어 모델은 정답의 기준이 모호하여 일정 수준 이상의 완벽성을 담보하기 어렵기 때문이다.