

1. LLM 에이전트 시스템 구조

1-1. 단일 LLM vs. 다중 에이전트 구조

단순한 AI 시스템은 LLM(Large Language Model) 하나로 구성되어 있으며, 프롬프트를 입력하면 출력이 나오는 방식이다. 하지만 이 방식은 복잡한 업무를 처리하기에 한계가 있다.

- 단일 LLM의 한계: AI 자체가 완전히 똑똑하지 않아 복잡한 작업에서 오류 발생
- 해결책: LLM을 여러 기능으로 쪼개어 각자 역할을 분담시키는 다중 에이전트 구조 사용
- 분업 예시: 라우터 에이전트 → 각 역할별 에이전트(FAQ, 인증, 데이터 조회 등) → 응답 생성 에이전트

1-2. 에이전트(Agent)

올해 AI 분야의 핵심 키워드

- 에이전트 = LLM 하나 (각각의 역할을 맡은 AI 모듈)
- 워크플로우 = 여러 에이전트를 연결한 전체 설계 구조
- 이 설계는 사람이 직접 → AI가 하는 게 아님

1-3. FDE (Forward Deployed Engineer)

FDE(전방 배치 기술자)는 클라이언트 회사에 직접 파견되어 AI 시스템을 설계·구축하는 역할이다. ex. 팔란티어(Palantir)

- 파견 형태: 대기업 기준 약 2명 파견, 1년 프로젝트
- 비용: 1인당 약 30억 원 수준 (연간 총 약 60억 원)
- 역할: 현장에서 직원들과 소통하며 AI 워크플로우를 설계

2. 에이전틱 AI (Agentic AI)

2-1. 개념

에이전틱 AI는 사람이 모든 단계를 지시하지 않아도 AI 스스로 계획을 세우고 자율적으로 업무를 수행하는 시스템을 말한다.

- 올해 AI 분야 1위 키워드
- 핵심 특징: '루프(Loop)'가 반드시 돌아야 함

- 구성: 플래너(Planner) → 실행기(Executor) → 평가기(Evaluator) → 피드백 루프

2-2. 작동 방식

- 플래너 LLM이 워크플로우 전체 설계를 자동으로 생성
- 실행기가 계획에 따라 업무 수행
- 평가기가 결과를 검토: 합격 시 완료, 불합격 시 플래너 또는 실행기로 재귀
- 루프가 며칠씩 돌 수 있으며, 토큰 사용량이 기하급수적으로 증가

2-3. 한계 및 주의사항

- AI가 설계한 워크플로우는 사람이 설계한 것보다 품질이 낮을 수 있음
- 되돌릴 수 없는 액션(구매, 예약 등)을 실행하면 위험
- 현재 에이전트 AI에 대한 기대가 다소 거품 상태일 수 있음

3. RAG (Retrieval-Augmented Generation)

3-1. RAG가 필요한 이유

LLM에 없는 특정 정보(사내 문서, 전문 데이터 등)를 활용해 답변을 생성해야 할 때, 컨텍스트 윈도우 제한으로 인해 전체 문서를 한꺼번에 입력할 수 없다.

- 컨텍스트 윈도우: LLM이 한 번에 처리할 수 있는 입력의 크기 제한
- 해결책: 문서를 잘게 쪼개어 벡터화하고, 질문과 유사한 청크만 선택해서 입력

3-2. RAG 동작 원리

- 문서를 문단(청크) 단위로 분할
- 임베더(Embedder, 임베딩 전용 LLM)로 각 청크를 벡터로 변환
- 질문도 동일한 임베더로 벡터화
- 코사인 유사도(Cosine Similarity)로 질문 벡터와 가장 유사한 청크 1~3개 선택
- 선택된 청크 + 원래 질문을 LLM에 전달하여 최종 답변 생성

3-3. RAG의 한계

- 텍스트가 벡터로 변환되면서 정보 손실(희석) 발생
- 최대 정확도 약 90% 수준 → 절대 오류가 허용되지 않는 분야(금융, 의료 등)에서는 사용 부적합

4. LLM 학습 3단계

4-1. 1단계: 프리트레이닝 (Pre-training)

- 세상에 존재하는 방대한 텍스트 데이터로 사전 학습
- 학습 방식: 토큰 n 입력 → 토큰 $n+1$ 예측 반복
- 결과: 언어를 유창하게 생성하는 모델 (단, 대화 능력은 아직 X)
- 소요 시간: 최신 GPU로도 수개월, 비용 수천억 원 수준

4-2. 2단계: 파인튜닝 (Fine-tuning)

- QA(질문-답변) 형식의 데이터로 추가 학습
- 모델이 대화형 응답을 잘 하도록 변환
- 데이터는 사람이 수만 건 이상 직접 제작
- 가중치(Weight, 파라미터): 행렬의 숫자 값 (학습 시 업데이트됨)

4-3. 3단계: RLHF (Reinforcement Learning from Human Feedback)

- 사람이 좋은 답변과 나쁜 답변에 O/X를 매겨 학습 데이터 구성
- 잘한 경우 강화(당근), 못한 경우 수정(채찍) → 강화학습 방식
- 목적: 욕설, 성적 표현, 핵 관련 정보 등 유해 답변 차단
- 아프리카 등 영어권 국가의 인력이 레이블링 작업에 대거 투입

5. 핵심 AI/IT 용어 정리

용어	설명
토큰 (Token)	LLM이 사용하는 기본 처리 단위. 단어보다 작을 수 있으며 모델마다 다름. 입출력 비용의 기본 단위.
임베딩 / 임베딩 벡터	텍스트·이미지 등을 AI가 계산할 수 있도록 고차원 숫자 벡터로 변환한 것
컨텍스트 윈도우	LLM이 한 번에 처리할 수 있는 최대 입력 크기
Hallucination	AI가 사실이 아닌 내용을 확신하며 답하는 오류
가중치 / 파라미터	AI 모델 내부의 행렬 숫자값. 학습 시 변경됨.
오버피팅 (과적합)	특정 학습 데이터에만 맞고 일반화되지 않는 상태. 반대말: 일반화(Generalization).

API	프로그램 기능을 외부에서 사용할 수 있도록 제공하는 부품, 인터페이스
클라이언트 / 서버	클라이언트: 사용자 기기(앱, 웹브라우저) 서버: 서비스를 제공하는 컴퓨터.
클라우드 컴퓨팅	서버 컴퓨터를 직접 구매하지 않고, AWS·Azure 등에서 빌려 쓰는 방식
AWS / Azure	양대 클라우드 플랫폼. AWS (아마존), Azure (마이크로소프트).
온프레미스 (On-premise)	인터넷 없이 자체 서버에서 운영하는 방식. 금융권 등 보안이 중요한 곳에서 사용.
SaaS / PaaS / IaaS	클라우드 서비스 유형. SaaS (소프트웨어), PaaS (플랫폼), IaaS (인프라) 형태로 제공.
프론트엔드 / 백엔드	프론트: 화면(HTML, CSS, JS). 백: 서버 로직(파이썬, Java, Node.js).
풀스택 (Full Stack)	프론트엔드와 백엔드를 모두 다루는 개발자. 현재는 당연한 기본값.
JSON	계층적 데이터를 표현하는 표준 포맷. AI 와 시스템 간 데이터 교환에 널리 사용.
RAG	Retrieval-Augmented Generation . 외부 문서를 벡터 검색해 답변에 활용하는 기법.
레거시 (Legacy)	기업이 기존에 보유하고 있는 전산 시스템
에자일 (Agile)	계획보다 빠른 실행을 우선하는 개발 방법론
MVP	Minimum Viable Product . 최소 기능만 갖춘 시제품으로 시장 반응 확인.
B2B / B2C	B2B : 기업 간 거래. B2C : 기업과 일반 소비자 간 거래.
UI / UX	UI : 화면 디자인. UX : 사용자가 느끼는 사용 경험.
PM (Project Manager)	프로젝트 전체를 총괄하는 역할. 기술 이해 + 커뮤니케이션 능력 필수.
레이턴시 (Latency)	LLM 요청 후 응답이 돌아오는 데 걸리는 시간

가드레일 (Guardrail)	AI가 특정 주제(욕설, 기밀 등)에 답하지 못하도록 프롬프트로 설정한 안전장치
휴먼인더루프 (Human-in-the-loop)	자동화된 AI 프로세스에 사람이 개입하여 확인·승인하는 방식
도메인 (Domain)	특정 산업·분야를 가리키는 말 (예: 금융 도메인, 의료 도메인)
정형 / 비정형 데이터	정형: 숫자·표 형식 데이터. 비정형: 텍스트·이미지 등.
VOC	Voice of Customer. 고객 불만·의견 등 고객의 소리 데이터.
RLHF	Reinforcement Learning from Human Feedback. LLM 3단계 학습 방식.

*용어의 중요성

- 문과생도 AI·IT 기본 용어는 반드시 숙지해야 하는 시대
- 커뮤니케이션 능력 + 기술 이해를 갖추면 PM 역할에서 강점 발휘 가능

*모르는 용어가 나왔을 때

- 타이밍을 놓치지 말 것 → 1~2초 안에 바로 질문
- 집요하게(Tenacious) 물어볼 것 (10번이라도)
- '인생은 타이밍' → 주저하는 순간 기회를 잃는다